



Sistem Inteligent de Diagnostic Ortodontic

Proiect PCLP3 - Partea I: Construirea, explorarea și modelarea unui dataset tabelar

Proiect realizat de Alexia Mitrache, seria 313CA

1. Introducere și Tipul Problemei

Proiectul meu este bazat pe domeniul **ortodonției**. Obiectivul clinic este evaluarea automată a indicatorilor dento-maxilari ai pacienților pentru a prezice dacă aceștia au nevoie de tratament cu aparat dentar.

- **Tipul Problemei:** Clasificare Binară. Variabila țintă este **Recomandare_Aparat** (1 = Tratament ortodontic indicat, 0 = Tratament neindicat în prezent).
- **Sursa Datelor:** Generare sintetică cu sens contextual medical realizată în **generate_data.py**. Logica de atribuire a etichetelor folosește o funcție de scor fundamentată pe corelații clinice reale (severitatea înghesurii dentare, tipurile de malocluzie și simptomatologia articulară), augmentată cu zgomot statistic Gaussian pentru a mimetiza variabilitatea biologică reală dintr-o clinică.

Structura și Tipul Datelor (8 coloane, 4 tipuri de date):

1. **id** - Identificator unic atribuit pacientului (**Număr întreg - int**)
2. **Varsta** - Vârsta biologică a pacientului, cuprinsă între 8 și 50 de ani (**Număr întreg - int**)
3. **Gen** - Categorie binară: 'Masculin' sau 'Feminin' (**Șir de caractere - Object**)
4. **Inghesuire_Dinti_mm** - Deficitul de spațiu pe arcada dentară (**Număr real - float**)
5. **Tip_Muscatuara** - Tipul de ocluzie: 'Normala', 'Overbite' (proeminență anterioară), 'Underbite' (mușcătură inversă) (**Șir de caractere - Object**)
6. **Dificultate_Masticatie** - Evaluare subiectivă a funcției masticatorii pe o scară de la 1 la 10 (**Număr întreg - int**)
7. **Durere_Mandibula** - Prezența simptomelor la nivelul articulației temporo-mandibulare (**Valoare logică - bool**)
8. **Recomandare_Aparat** [**VARIABILA ȚINTĂ**] - Decizia clinică finală: 0 sau 1 (**Număr întreg - int**)

2. Împărțirea Datasetului și Salvarea Fișierelor

Setul total de 900 de cazuri simulate a fost amestecat pseudo-aleator și separat în două subseturi complet disjuncte, salvate local ca fișiere CSV:

- **Subset de Antrenare (**train.csv**):** Conține 600 de instanțe (utilizat pentru calcularea statisticilor de bază, imputare și potrivirea modelului).
- **Subset de Testare (**test.csv**):** Conține 300 de instanțe (păstrat complet izolat pentru evaluarea finală a performanței generale).


3. Analiza Exploratorie a Datelor (EDA) — Concluzii Clinice


a) Gestiunea Valorilor Lipsă

Rularea scriptului `explore_data.py` a scos la iveală un procent de aproximativ 2.5% de valori lipsă (NaN), introduse intenționat doar pe coloana `Inghesuire_Dinti_mm`. Pentru a nu pierde date prețioase prin ștergerea rândurilor, am ales să înlocuiesc aceste lipsuri cu **mediana** setului de antrenare. Am preferat mediana în locul mediei, deoarece este mult mai stabilă și nu este influențată de valorile extreme din clinică.

b) Distribuția Variabilelor


Analiza grafică ne arată că variabila `Varsta` are o distribuție uniformă, ceea ce înseamnă că avem suficienți pacienți din toate categoriile (copii, tineri și adulți). Coloana `Inghesuire_Dinti_mm` urmează o curbă descrescătoare: majoritatea oamenilor au probleme ușoare, în timp ce cazurile foarte grave sunt rare. La tipurile de mușcătură, cazurile de `Underbite` (mușcătură inversă) sunt cele mai puține, lucru care reflectă perfect realitatea din cabinetele stomatologice.






c) Analiza Outlierilor

Folosind regula statistică IQR (bazată pe intervalul intercuartilic), am detectat o serie de valori atipice (outlieri) în zona superioară a coloanei **Inghesuire_Dinti_mm** (pacienți cu o înghesuire de peste 6-7 mm). Am decis să **păstrez acești outlieri** în setul de date. Ei nu sunt greșeli de tastare, ci reprezintă pacienți reali cu probleme ortodontice severe. Dacă i-am fi șters, modelul nu ar fi fost capabil să recunoască exact cazurile cele mai grave, care au cea mai mare nevoie de aparat.




d) Heatmap-ul Corelațiilor

Matricea de corelație arată o legătură liniară foarte puternică între **Inghesuire_Dinti_mm** și decizia **Recomandare_Aparat** ($r \approx 0.60$). A doua variabilă ca importanță este **Dificultate_Masticatie**. Surprinzător, vârsta are o corelație aproape de zero cu decizia finală, ceea ce demonstrează că severitatea problemelor fizice primează în fața vârstei atunci când se recomandă un aparat dentar.



e) Relația cu Variabila Țintă

Graficele de tip violin plots arată o separare clară între pacienți. La cei care au primit recomandare de aparat (1), formele graficului sunt umflate în partea de sus, adică în zona valorilor mari de înghesuire dentară și dificultate la masticare, confirmând că modelul are o bază logică solidă pentru decizii.



4. Antrenarea și Evaluarea Modelului de Bază (Baseline)

În cadrul scriptului `baseline_model.py`, am antrenat un model de Regresie Logistică (`LogisticRegression`). Înainte de antrenare, am transformat variabilele text (Gen, Tip_Muscatura, Durere) în format numeric folosind One-Hot Encoding. De asemenea, am aliniat coloanele setului de test cu cele de la antrenare pentru a evita eventualele erori cauzate de categorii lipsă.

Metricile obținute pe setul de test (300 de pacienți noi):

Acuratețe (Accuracy): 92.00% — Modelul clasifică corect 92% din totalul pacienților noi.


Precizie (Precision): 93.01% — Dintre toți pacienții pe care modelul îi trimite spre aparat, 93% au cu adevărat nevoie de el (rată mică de alarme false).

Sensibilitate (Recall): 98.52% — Aceasta este cea mai importantă metrică medicală: modelul reușește să descopere și să nu scape nediagnosticați 98.52% din totalul oamenilor care chiar au probleme.

Scor F1 (F1-Score): 0.9568 — Reprezintă media armonică dintre precizie și sensibilitate, confirmând un echilibru excelent.

Interpretarea Matricei de Confuzie ([matrice_confuzie.png](#))

Din totalul de 300 de cazuri independente, modelul a înregistrat **266 de cazuri True Positive** și **10 cazuri True Negative**. Erorile au fost extrem de reduse: doar **4 cazuri False Negative** (pacienți ratați) și **20 de cazuri False Positive** (pacienți trimiși preventiv către specialist). Acest profil de eroare este ideal într-un context de diagnostic medical primar.



5. BONUS - Aplicația Interactivă Gradio ([app.py](#))

Am dezvoltat o aplicație grafică completă în scriptul [app.py](#), proiectată special ca o consolă de asistență pentru medicii ortodonti din cabinete.

Detalii de implementare și protecție:

Aplicația se conectează direct la logica din model. În momentul în care medicul introduce datele unui pacient nou pe ecran, codul transformă datele într-un [DataFrame](#), aplică [One-Hot Encoding](#) în timp real și verifică structura exactă a coloanelor. Dacă anumite categorii nu sunt selectate, aplicația adaugă automat valoarea 0, prevenind astfel prăbușirea eronată a programului în timpul consultației.

Cum este organizată interfața (Tab-uri):

- Sistem Intelligent de Diagnostic Ortodontic (Proiect PCLP3)

Aplicație clinică interactivă bazată pe modelul de Regresie Logistică (Acuratețe: 91.33%).

Diagnostic în Direct

Performanță Model (Vizualizări)

Introducere Date Clinic

Vârstă (ani)

19

U

8

50

Gen

Masculin

Feminin

Inghesuire Dinți (mm)

0

U

0

10

Tipul Mușcăturii

Normala

Dificultate Masticatie (1-10)

3

U

1

10

Prezență Durere Mandibulară

Da

Nu

Calculează Diagnostic

Rezultat Evaluare

Verdict Final

RECOMANDARE: TRATAMENT ORTODONTIC NEINDICAT
Pacientul nu necesită aparat dentar în acest moment.

Probabilitățile Fiecărei Clase

Nu are nevoie

Are nevoie de aparat

52%

48%

Use via API

Built with Gradio

Settings

Sistem Inteligent de Diagnostic Ortodontic (Proiect PCLP3)

Aplicație clinică interactivă bazată pe modelul de Regresie Logistică (Acuratețe: 91.33%).

Diagnostic în Direct [Performanță Model \(Vizualizări\)](#)

Matricea de Confuzie obținută pe setul de Testare

Matrice de Confuzie

